

Séquence N° 4 - Statistiques descriptives

Chaque pays de l'Union européenne a déterminé l'âge moyen du départ du domicile parental des enfants en 2012 et 2021. Les résultats sont donnés dans le tableau ci-dessous :

Âge	19	20	21	22	23	24	25	26	27	28	29	30	31	32	33	34
Effectif 2012	0	1	1	1	0	3	4	2	2	2	6	3	1	1	0	0
Effectif 2021	1	0	1	1	2	2	2	2	4	2	1	5	2	0	1	1

1 Autour de la moyenne

On considère une série statistique de p valeurs distinctes, $x_1, x_2, \dots, x_p$, d'effectifs respectifs $n_1, n_2, \dots, n_p$:

Valeur	x_1	x_2	...	x_p
Effectif	n_1	n_2	...	n_p

Si tous les effectifs avaient la même valeur, alors ce serait la moyenne $\bar{x}$.

On peut la calculer avec la formule :

$$\bar{x} = \frac{\sum_{i=1}^p n_i x_i}{\sum_{i=1}^p n_i}$$

La moyenne est un **indicateur de position**, permettant ainsi de situer la valeur d'une série statistique.

1. Calculez les moyennes $\bar{x}$ des 2 séries.

Pour mesurer la dispersion d'une série autour de la moyenne, on utilise l'**écart-type** σ de la série statistique (c'est un **indicateur de dispersion**). On peut le calculer avec la formule :

$$\sigma = \sqrt{\frac{\sum_{i=1}^p n_i (x_i - \bar{x})^2}{\sum_{i=1}^p n_i}}$$

- **Plus l'écart-type σ est petit**, plus les valeurs de la série sont **homogènes** (les valeurs de la série sont plus concentrées autour de la moyenne) ;
- **Plus l'écart-type σ est grand**, plus les valeurs de la série sont **hétérogènes** (les valeurs de la série sont plus éloignées de la moyenne) ;

2. Calculez les écart-types σ des 2 séries.

.....

.....

.....

.....

.....

3. Quelle proportion des valeurs des séries de 2012 et 2021 sont dans l'intervalle $[\bar{x} - \sigma; \bar{x} + \sigma]$?

.....

.....


.....

.....

.....

Si l'échantillon de données est assez grand, on peut dire que :

- environ 68% des données sont situées dans l'intervalle $[\bar{x} - \sigma; \bar{x} + \sigma]$;
- environ 95% des données sont situées dans l'intervalle $[\bar{x} - 2\sigma; \bar{x} + 2\sigma]$;
- environ 99% des données sont situées dans l'intervalle $[\bar{x} - 3\sigma; \bar{x} + 3\sigma]$;



2 Autour de la médiane

On considère une série statistique **ordonnée** d'effectifs n :

- La médiane Med est la valeur qui partage la série en 2 parties égales.
Si n est impair, la valeur de Med sera la valeur du rang $\frac{n+1}{2}$.
Si n est pair, la valeur de Med sera la moyenne des valeurs des rangs $\frac{n}{2}$ et $\frac{n}{2} + 1$.
- Le 1er quartile Q_1 est la plus petite valeur de la série tel que 25% des données lui sont inférieures ou égales.
Le rang de Q_1 est le plus petit entier supérieur ou égal à $0,25 \times n$.
- Le 3ème quartile Q_3 est la plus petite valeur de la série tel que 75% des données lui sont inférieures ou égales.
Le rang de Q_3 est le plus petit entier supérieur ou égal à $0,75 \times n$.

4. Calculez la médiane et les quartiles de la série des âges de départ en 2012.

Âge de départ	19	20	21	22	23	24	25	26	27	28	29	30	31	32	33	34
Effectifs 2012																
Cumulés 2012																

Calculez la médiane et les quartiles de la série des âges de départ en 2021.

Âge de départ	19	20	21	22	23	24	25	26	27	28	29	30	31	32	33	34
Effectifs 2021																
Cumulés 2021																

5. Sans calcul supplémentaire et **en justifiant** peut-on affirmer qu'au moins la moitié des valeurs de la série de 2012 est dans l'intervalle $[25; 29]$?

6. Sans calcul supplémentaire et **en justifiant** peut-on affirmer qu'au moins 75% des valeurs de la série de 2012 sont supérieures ou égale à 29 ?

.....

.....

.....

Les **indicateurs de dispersion** mesurant l'étalement des valeurs d'une série autour de la médiane sont l'**étendue**, l'**écart-type** et l'**écart interquartile**.

- L'**étendue**, notée e , d'une série statistique est la différence entre la plus grande et la plus petite valeur de la série.

$$e = Max - min$$

Elle mesure la dispersion totale des valeurs de la série.

- L'**écart interquartile** est la différence entre le troisième et le premier quartile, $Q_3 - Q_1$. Il mesure la dispersion des valeurs de la série autour de la médiane.

7. Calculez les indicateurs de dispersion autour de la médiane des deux séries. Quelle est la série la plus homogène ?

.....

.....

.....


.....

.....

3 Comparer des séries statistiques

Une série statistique est caractérisée par ses indicateurs de position et de dispersion. Pour "résumer" une série, on peut étudier les couples $(\bar{x}, \sigma)$ (autour de la moyenne) ou $(Med, Q_3 - Q - 1)$ (autour de la médiane).

Le couple $(\bar{x}, \sigma)$ est plus sensible aux **valeurs extrêmes** que le couple $(Med, Q_3 - Q - 1)$. Par exemple, le salaire médian peut être plus représentatif que le salaire moyen (*source : La Finance pour Tous*) :




Pour comparer 2 séries statistiques, on compare les couples autour de la moyenne ou autour de la médiane.

Le couple $(\bar{x}, \sigma)$ sera préféré pour créer des indicateurs statistiques chiffrés tandis que le couple $(Med, Q_3 - Q - 1)$ sera préféré pour pouvoir comparer "graphiquement" (notamment avec le *diagramme en boîte à moustaches*).


7. Comparez les deux séries.

Un diagramme en boîte à moustaches rassemble graphiquement le minimum min , le maximum Max , la médiane Med et les quartiles Q_1 et Q_3 d'une série statistique.



Les diagrammes en boîte à moustaches permettent de comparer et interpréter des séries statistiques : médianes, écarts interquartiles (longueurs des boîtes) et étendues (longueurs des diagrammes).

8. Construisez ci-dessous les diagrammes en boîte à moustache des deux séries.



Feuille obtenue gratuitement sur www.desmoulins.fr

Est-ce que ça confirme les conclusions précédentes ?

.....

.....

.....

.....

Exercices d'application

Exercice 1 - Autour de la moyenne

Dans un lycée général et technologique, la répartition du nombre d'élèves par classe est donnée par le tableau suivant.

Nombre d'élèves	16	24	27	28	29
Nombre de classes	1	3	1	2	3

Nombre d'élèves	30	31	32	33	34
Nombre de classes	2	3	6	2	4

1. Calculez le nombre moyen d'élèves par classe dans ce lycée.
2. Calculez l'écart-type de cette série.

Exercice 2 - Autour de la moyenne

On considère la série suivante donnant le nombre de jours de congés payés annuels par pays de l'Union Européenne.

Nombre de jours de congés payés	20	22	24	25	28
Nombre de pays	17	2	2	5	1

1. Calculez le nombre moyen de jours de congés payés $\bar{x}$ dans les pays de l'Union Européenne.
2. Calculez l'écart-type σ de cette série.
3. Est-ce que le nombre de congés payés de la France se situe dans l'intervalle $[\bar{x} - \sigma; \bar{x} + \sigma]$? Qu'est-ce que ça signifie pour la France?

Exercice 3 - Ecart-type


Le tableau suivant donne les temps (en minutes) des 5 entraînements hebdomadaires d'Aman pour participer au semi-marathon de Paris ces deux dernières semaines.

Semaine 1	22	33	35	25	12
Semaine 2	25	25	26	23	27

1. Sans calcul, quelle semaine l'écart-type de la série des temps est le plus petit?
2. Vérifiez en déterminant ces écart-types.

Exercice 4 - Autour de la médiane

On donne ci-dessous la répartition des revenus en euros des personnes vivant seules en France en 2018.



1. Quelle proportion de ces personnes a un revenu annuel de 20 000 € ou moins?
2. Déterminez la médiane et les quartiles de cette série et les interpréter concrètement.

Exercice 5 - Autour de la médiane

Les autorités d'une île isolée ont décidé d'installer une éolienne. L'éolienne choisie fonctionne lorsque le vent atteint au moins 8 nœuds et il faut l'arrêter lorsque le vent atteint ou dépasse 48 nœuds.

1. Les autorités décident de mesurer pendant un mois la vitesse du vent, en nœuds, au sommet d'une montagne.

Une mesure est effectuée chaque jour. Voici les résultats :

Vitesse	7	14	16	18	20	22
Effectif	1	2	1	1	4	5

Vitesse	24	26	27	30	44	50
Effectif	3	4	4	2	1	2

Par exemple, il y a 5 jours où la vitesse est de 22 nœuds.

- (a) Quelle proportion de jours de ce mois l'éolienne aurait-elle pu fonctionner ?
 - (b) Déterminez la médiane et l'écart interquartile de cette série statistique.
2. Un emplacement sur une falaise a été également retenu.
Le même mois, on y a mesuré les vitesses du vent et on a obtenu : $Q'_1 = 14$, $Med' = 22$ et $Q'_3 = 34$.
Peut-on affirmer que la vitesse du vent est comprise entre 22 et 34 nœuds inclus au moins 50% du temps ? Justifiez.
 3. Sachant qu'une éolienne a un rendement optimal aux alentours de 23 nœuds, quel site paraît le plus intéressant pour l'installation de l'éolienne ?

Exercice 6 - Comparer des séries

On donne ci-dessous le nombre moyen d'élèves par classe dans les pays de l'Union Européenne sur l'année 2019-2020 (les données pour la Belgique, l'Irlande, les Pays-Bas et le Luxembourg sont manquantes).

20,9	18,3	19,6	21,9	18,7	18,7
22,1	17	22	18,7	16,8	17,7
16,6	20,5	18,3	20,3	18,7	20,3

(Source : DEPP, l'Europe de l'éducation en chiffres.)

1. (a) Déterminez le minimum, le maximum, les quartiles et la médiane de cette série.
(b) En 2010, ces indicateurs étaient les suivants pour ces pays.

Min	Q_1	Médiane	Q_3	Max
15,3	17,9	18,8	20,1	22,7

(Source : OCDE, les données de la Suède ne sont pas disponibles)

Commentez l'évolution de ces données entre 2010 et 2020.

- (c) En 2010, la moyenne des nombres moyens d'élèves par classe dans ces pays était d'environ 19 et l'écart-type de 1,9.

La moyenne et l'écart-type semblent-ils confirmer la réponse à la question précédente ?

2. On s'intéresse dans cette question au nombre moyen d'élèves par classe au collège dans ces pays sur les deux mêmes périodes dont on donne les indicateurs ci-dessous.

	2010	2019-2020
Minimum	16,8	16,7
Q_1	20,3	19,5
Médiane	21,4	20,5
Q_3	22,1	21,9
Maximum	24,7	25,6
Moyenne	21,3	20,8
Écart-type	2	2,3

L'évolution des nombres moyens d'élèves par classe en collège sur ces deux périodes est-elle similaire à celles des nombres moyens d'élèves en école élémentaire ?

3. Le tableau suivant donne les nombres moyens d'élèves par classe en France.

	2010	2019-2020
École élémentaire	22,7	22,1
Collège	24,5	25,6

Le nombre moyen d'élèves par classe en France en école et en collège a-t-il suivi la tendance européenne ?

Exercice 7 - Comparer des séries

Sur une plateforme de location de logements, un appartement a obtenu les notations suivantes.

Nombre d'étoiles	1	2	3	4	5
Nombre de clients	5	32	65	23	2

- Déterminez la moyenne et l'écart-type de cette série.
- Déterminez la médiane, les quartiles et l'écart interquartile de cette série.
 - Sans calcul, peut-on affirmer qu'au moins 75% des clients ont donné une note inférieure ou égale à 3 étoiles ? Justifiez.
- Représentez cette série statistique par un diagramme en boîte à moustache (*prévoyez de la*

place pour une deuxième boîte sur le même diagramme).

- Les propriétaires de l'appartement y ont fait faire des travaux d'aménagement. Depuis les travaux, le logement a obtenu les notations suivantes.


Nombre d'étoiles	1	2	3	4	5
Nombre de clients	2	5	9	22	10

- Représentez le diagramme en boîte sur le diagramme précédent.
- Que peut-on en déduire graphiquement en termes d'homogénéité et de qualité des notes ?
- Confirmez la réponse à l'aide de la moyenne et de l'écart-type.

Exercices d'approfondissement

1 - Débits de la Seine

Les courbes ci-dessous donnent les débits de la Seine en m^3/s durant tout l'automne 2022 dans les stations hydrométriques d'Alfortville et de Vernon.



- Dans laquelle de ces deux villes :
 - le débit moyen est-il le plus élevé ?
 - le débit semble-t-il être le plus homogène ?
- On rassemble les débits quotidiens en m^3/s sur l'automne 2022 en classes.

Débit à Alfortville	[50 ; 100[	[100 ; 150[	[150 ; 200[
Nombre de jours	28	58	5

Débit à Vernon	[150 ; 200[	[200 ; 250[	[250 ; 300[	[300 ; 350[
Nombre de jours	14	51	21	5

- Calculez les moyennes et les écarts-types de ces deux séries en prenant les centres des classes comme valeurs puis contrôlez vos résultats à la question 1.
 - Donnez un encadrement du 1er quartile de la série des débits quotidiens de la Seine à Vernon durant l'automne 2022.
 - Justifiez que le débit de la Seine à Vernon a été supérieur à celui d'Alfortville au moins 75% de l'automne 2022.
- Comment expliquer que le débit de la Seine soit largement plus élevé à Vernon qu'à Alfortville ?

2 - Statistiques commerciales

Un groupe d'optique décide d'évaluer la vente des différentes montures (CLASSIQUE et SPORT) et a donc effectué une étude statistique sur trois magasins pendant un an.

Le nombre de ventes par mois (comptées 50 par 50) ont été regroupées dans le tableau suivant :

Nombre de ventes	0	50	100	150	200	250	300	400	500
Nombre de mois CLASSIQUE	0	4	5	10	11	4	1	1	0
Nombre de mois SPORT	3	8	8	8	2	2	1	1	3

Les résultats seront arrondis, le cas échéant, à l'unité.

1. Calculer les moyennes et écart-types des deux séries statistiques.
2. Que peut-on dire des ventes des différentes montures à partir de ces indicateurs ?
3. Tracer les diagrammes en boîte à moustache des deux séries.
4. D'après ces diagrammes, quelle est la monture qui se vend le mieux dans les magasins ?